GUÍA DEL ESTUDIANTE

Práctica 1 — Regla vs modelo

Duración	60 minutos
Modalidad	Individual
Archivos	`actividad_usuarios.csv` (datos) `practica_1_2.py` (script base)
Requisitos	Python 3.10 o superior librerías `pandas` y `scikit-learn`
Entregable	Un pdf con los resultados, las tablas completadas y una reflexión de 5 a 10 líneas

1. ¿De qué trata esta práctica?

Trabajas como analista SOC en la empresa Laboon. Un equipo de monitoreo te entrega un registro de actividades de usuarios (cada fila es un usuario en un día) y te pide encontrar cuentas comprometidas. Sospechas que hay atacantes mezclados con la actividad normal, pero **nadie sabe exactamente cuáles son**. Vas a comparar dos formas de detectarlos:

- **Una regla escrita por una persona**: "si un usuario falla más de 5 veces al iniciar sesión, es fuerza bruta".
- **Un modelo de aprendizaje automático** (Isolation Forest) que aprende por sí mismo qué es lo habitual y marca lo que se aparta.

El atacante de este ejercicio es **«lento y silencioso»**: casi no falla contraseñas, pero se conecta de madrugada y envía mucho volumen de datos al exterior. La pregunta de fondo es: **¿qué detecta cada enfoque y qué se le escapa?**

2. Objetivos de aprendizaje

Al terminar la práctica serás capaz de:

- Leer y explorar un conjunto de datos de actividad de usuarios con `pandas`.
- Aplicar una regla de detección y un modelo no supervisado sobre los mismos datos.
- Interpretar una matriz de confusión y calcular recall, precisión y falsos positivos.
- Explicar por qué la exactitud (accuracy) engaña cuando los ataques son pocos.
- Describir el compromiso entre detectar más ataques y recibir más falsas alarmas.
- Razonar cómo un atacante podría adaptarse para evadir un detector.

3. Datos y preparación

Conceptos que necesitas saber:

Concepto	Qué significa	En esta práctica
Regla	Una condición escrita por una persona. Es precisa y fácil de explicar, pero solo cubre lo que alguien anticipó.	`failed_logins > 5`
Modelo no supervisado	Aprende patrones sin que le digan cuáles son ataques. Marca lo que se aparta de lo habitual.	Isolation Forest
Falso positivo (FP)	Actividad normal marcada como ataque. Genera trabajo inútil para el analista.	Un usuario normal que el detector marca
Falso negativo (FN)	Ataque que el detector no vio. Es el error más peligroso.	Un atacante que pasa como normal
Recall	De los ataques que existen, qué fracción detectaste: TP / (TP + FN).	Ataques detectados sobre 40
Precisión	De lo que marcaste como ataque, qué fracción lo era: TP / (TP + FP).	Qué tan confiable es una alerta
Exactitud (accuracy)	Fracción de aciertos totales. Engaña con clases muy desiguales.	Hay solo 40 ataques entre 2.040 filas

El archivo `actividad_usuarios.csv` tiene 2.040 filas y 7 columnas:

Columna	Descripción
`event_id`	Identificador del evento (E0001, E0002, …)
`user`	Usuario ficticio (u001 a u120)
`date`	Fecha del evento (septiembre de 2026)
`failed_logins`	Cantidad de intentos de inicio de sesión fallidos en el día
`hour`	Hora media de la actividad (de 0 a 24, en decimales: 13,5 = 13:30)
`mb_out`	Megabytes enviados al exterior en el día
`is_attack`	0 = actividad normal, 1 = ataque. Obs. solo sirve para evaluar, el modelo no la usa para aprender

Nota: El modelo solo usa tres columnas: `failed_logins`, `hour` y `mb_out`. Las columnas `user` y `date` no se usan en esta práctica.

4. Desarrollo

Parte 1: inicio

1. Crea una carpeta con tu primer nombre y primer apellido juntos (p.e. juanperez), dentro de esta carpeta descomprime el archivo laboratorio.zip y ejecuta el archivo practica_1_2.py. saca una captura de pantalla con el resultado (no debe tener errores ni warnings).
2. Copia la matriz en la tabla de resultados (sección 6) y responde: ¿cuántos de los 40 ataques detectó la regla? ¿Por qué?
3. Completa la tabla de métricas y responde: la regla tiene una exactitud cercana al 98 %, pero no detectó ningún ataque. ¿Cómo es posible?

Parte 2: ¿cuántas anomalías esperar?

El parámetro `contamination` le dice al modelo qué proporción de anomalías debe esperar. En este ejercicio 0,02 coincide con la realidad (40 de 2.040), pero **en la vida real no se conoce ese dato**. Prueba valores diferentes y responde:
¿Qué ocurre con las falsas alarmas cuando subes contamination? ¿Y con los ataques perdidos cuando lo bajas? Si tuvieras que elegir un valor para un equipo con poco tiempo, ¿cuál elegirías y por qué?

Parte 3: piensa como atacante

Imagina que el atacante descubre que lo detectan por su horario y su volumen de acciones y decide adaptarse, envía menos datos por día y se conecta en horario laboral. Simúlalo modificando solo las filas de ataque:

```
atq = df["is_attack"] == 1
X2 = X.copy()
X2.loc[atq, "mb_out"] = X2.loc[atq, "mb_out"] * 0.3   # reparte el volumen
# Para probar también el cambio de horario, quita el # de la línea siguiente:
# X2.loc[atq, "hour"] = 11.0

m2 = IsolationForest(contamination=0.02, random_state=42).fit(X2)
pred2 = (m2.predict(X2) == -1).astype(int)
print(confusion_matrix(y, pred2))
```

¿cambió el número de ataques detectados? Prueba con distintos factores (0,5; 0,3; 0,15), con y sin el cambio de horario. ¿A partir de qué punto el modelo deja de ver al atacante? ¿Qué podría hacer la empresa para detectarlo igualmente (qué otra información o qué otra regla agregarías)?

5. Cómo interpretar una matriz de confusión

`confusion_matrix(y, prediccion)` devuelve una tabla de 2 × 2. Las filas son lo que realmente era cada evento y las columnas lo que dijo el detector:

	Detector dijo: normal (0)	Detector dijo: ataque (1)
Realmente normal (0)	Verdaderos negativos (TN): bien ignorado	Falsos positivos (FP): falsa alarma
Realmente ataque (1)	Falsos negativos (FN): ataque que pasó	Verdaderos positivos (TP): ataque detectado

La fila de abajo es la que más importa: cuantos más ataques caen a la derecha, mejor detecta el sistema. Para verificar tu trabajo, estos son los valores de referencia que debes obtener con el CSV entregado:

Detector	Matriz [[TN, FP], [FN, TP]]	Lectura
Regla	[[2000, 0], [40, 0]]	0 ataques detectados, 0 falsas alarmas
Modelo	[[1997, 3], [2, 38]]	38 ataques detectados, 3 falsas alarmas, 2 ataques perdidos

6. Tablas para completar y entregar

Parte 1: inicio

Captura de pantalla:

Matrices de confusión que obtuviste

	Regla	Modelo
Verdaderos negativos (TN)		
Falsos positivos (FP)		
Falsos negativos (FN)		
Verdaderos positivos (TP)		

Métricas

Métrica	Regla	Modelo
Recall		
Precisión		
Accuracy		
Falsas alarmas (FP)		

Parte 2: ¿cuántas anomalías esperar?

contamination	Ataques detectados	Falsas alarmas	Ataques perdidos
0,005			
0,01			
0,02			
0,05			
0,10			

Si tuvieras que elegir un valor para un equipo con poco tiempo, ¿cuál elegirías y por qué?
Valor:
Porque:

Parte 3: piensa como atacante

Variante del atacante	Ataques detectados	Falsas alarmas	Ataques perdidos
Original (factor 1,0)			
Volumen × 0,5			
Volumen × 0,3			
Volumen × 0,3 y hora 11,0			
Tu propia variante: _____			

Parte 4: análisis

Escribe entre 5 y 10 líneas respondiendo a estas preguntas guía:

1. ¿Falló la regla? ¿O hizo exactamente lo que se le pidió?

2. ¿Qué ventajas tuvo el modelo? ¿Qué desventajas (falsas alarmas, falta de explicación de por qué marcó cada caso)?

3. ¿Por qué crees que en la práctica se suelen combinar reglas y modelos en lugar de elegir uno solo?

4. ¿Qué riesgos ves en confiar ciegamente en un modelo de detección?