GUÍA DEL ESTUDIANTE

Práctica 2 — Análisis exploratorio de CIC-IDS2017

Duración	60 minutos en clase
Modalidad	Individual
Archivos	`eda_cicids2017.py` (script de trabajo) Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv (de CIC-IDS2017)

Requisitos	Python 3.10 o superior
	librerías `pandas`
	`numpy`
	`matplotlib`
	`scikit-learn` (opcional: `pyarrow`)

Entregable	Un informe de exploración (notebook o documento) con las respuestas, los gráficos principales, las tablas completadas y el dataset limpio

1. ¿De qué trata esta práctica?

Antes de entrenar cualquier modelo hay que **conocer los datos**: cuántos son, cómo se reparten las clases, qué errores traen y qué variables parecen separar un ataque del tráfico normal. A esa fase se le llama análisis exploratorio (EDA). Un modelo sofisticado entrenado sobre datos mal entendidos puede mostrar un rendimiento espectacular y no servir para nada.

En esta práctica se utilizará la colección de documentos **CIC-IDS2017**, específicamente el archivo de ataques DDoS.

2. Objetivos de aprendizaje

Al terminar la práctica serás capaz de:

- Cargar un CSV grande de tráfico de red y revisar su estructura.
- Medir el desbalance de clases y explicar por qué importa.
- Detectar y tratar problemas de calidad: valores faltantes, infinitos, negativos, columnas constantes y duplicados.
- Comparar variables entre tráfico benigno y ataque usando escala logarítmica.
- Identificar variables redundantes (correlación) y variables sospechosas de ser un atajo.
- Documentar decisiones razonadas para dejar el dataset listo para modelar (práctica 2.3).

3. Cómo obtener los datos

El dataset se descarga del sitio del Canadian Institute for Cybersecurity (buscar CIC-IDS2017) y trae dos carpetas. Los nombres pueden variar según la descarga, así que ante cualquier duda seguir las siguientes indicaciones:

- **MachineLearningCVE** (versión para aprendizaje automático): un CSV por franja horaria, con las características y la etiqueta, sin IPs ni marcas de tiempo. Es la que usaremos en esta práctica.
- **TrafficLabelling** (flujos etiquetados): trae además Flow ID, direcciones IP, puerto de origen y marcas de tiempo. El script también la acepta: muestra esas columnas en la sección 3b y las excluye del análisis.

El dataset completo es grande, así que se trabajará con un solo día (o con dos como máximo). A continuación se muestra una tabla de referencia de los archivos, con valores aproximados tomados de la documentación y de la literatura sobre el dataset; tu copia puede diferir ligeramente según la versión:

Día / franja	Ataques que contiene	Filas aprox.	Reparto aproximado
Lunes	Ninguno (solo tráfico benigno)	530 mil	100 % benigno
Martes	Fuerza bruta FTP y SSH (Patator)	446 mil	≈ 3 % ataques
Miércoles	DoS (Hulk, GoldenEye, slowloris, Slowhttptest) y Heartbleed	693 mil	≈ 37 % ataques
Jueves (mañana)	Ataques web (fuerza bruta, XSS, inyección SQL)	170 mil	≈ 1,3 % ataques
Jueves (tarde)	Infiltración	289 mil	36 flujos de ataque
Viernes (mañana)	Botnet	191 mil	≈ 1 % ataques
Viernes (tarde) — recomendado	**DDoS**	**226 mil**	**≈ 57 % ataques**
Viernes (tarde)	Escaneo de puertos (PortScan)	286 mil	≈ 55 % ataques

¿Por qué el viernes de DDoS? Es un archivo de tamaño manejable y con muchos ejemplos de ataque, ideal para este laboratorio. En una ejecución real de este archivo se obtuvieron 225.745 filas: 128.027 DDoS (56,7 %) y 97.718 benignos (43,3 %).

4. Preparación y ejecución

Organiza una carpeta de trabajo con el script y el CSV, como el anterior laboratorio crea una carpeta con tu nombre y apellido, e instala las librerías si hace falta.
Ejecuta el análisis completo con un solo comando:

```
python eda_cicids2017.py Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv

# Opciones útiles
#   --salida mi_carpeta   carpeta donde se guardan gráficos y resultados
#   --muestra 10000       filas de la muestra (si tu equipo va lento)
#   --semilla 7           cambia la semilla de las muestras aleatorias

# Varios archivos a la vez (se combinan en uno solo)
python eda_cicids2017.py dia1.csv dia2.csv --salida eda_dos_dias
```

5. ¿Qué produce el script?

N°	Sección del informe	Qué obtienes
1	Carga de datos	Filas y columnas por archivo; nombres de columna normalizados
2	Estructura	Tipos de dato, memoria y columnas con nombre repetido

N°	Sección del informe	Qué obtienes
3	Distribución de clases	Tabla de conteos y porcentajes, razón mayoritaria/minoritaria. Gráfico `01_distribucion_clases.png`
3b	Columnas de identificación	Solo con TrafficLabelling: muestra qué IPs concentran los ataques y excluye esas columnas del análisis
4	Calidad del dato	Faltantes, infinitos, negativos, flujos de duración 0 y columnas constantes
5	Limpieza	Filas antes y después de quitar inf/NaN y duplicados, filas eliminadas por clase y cambio en la proporción de ataques
6	Comparación entre clases	Mediana y media por clase, variedad de valores distintos. Gráficos `02_histogramas_log.png` y `03_cajas_log.png`
7	Correlaciones	Mapa de calor `04_correlacion.png` y lista de pares con $\|r\| \geq 0{,}95$
8	Poder separador	AUC de cada variable por sí sola y marca de las variables sospechosas. Gráfico `05_poder_separador.png`
9	Puertos de destino	Top 10 de puertos por clase y prueba de una regla de una sola condición con el puerto del ataque. Gráfico `06_puertos_destino.png`
10	PCA	Varianza explicada y proyección en 2D. Gráfico `07_pca.png`
11	Salidas	`resumen_eda.txt` (todo el texto del informe) y `cic_limpio.parquet` o `cic_limpio.csv.gz`

6. Desarrollo guiado

Ejecuta el script una vez y luego recorre las tareas siguiendo el informe de pantalla (o `resumen_eda.txt`) y los gráficos. Anota tus respuestas y valores en las tablas de la sección 7.

Tarea 1 · Estructura del dataset (sección 2)

- ¿Cuántas filas y columnas tiene tu archivo? ¿Cuántas son características y cuál es la etiqueta?
- ¿Qué columna aparece con nombre repetido y qué significa que pandas la haya renombrado con ".1"?
- ¿Por qué crees que los nombres originales traían espacios al inicio? ¿Qué problema causaría eso al escribir `df["Flow Duration"]`?

Tarea 2 · Distribución de clases (sección 3)

- ¿Qué porcentaje del archivo es ataque? ¿Cuál es la razón entre clase mayoritaria y minoritaria?
- Si en tu red real el 0,01 % del tráfico fuera malicioso, ¿qué te dice eso sobre este archivo? (Recuerda el ejemplo de la tasa base de la clase 1.)
- Un modelo que dijera siempre "es ataque", ¿qué exactitud tendría en este archivo? ¿Y uno que dijera siempre "benigno"?

Tarea 3 · Calidad del dato (sección 4)

- ¿En qué columnas hay valores infinitos y faltantes? ¿Cuántos? ¿Coinciden con los flujos de duración 0? Explica por qué (pista: se calcula bytes ÷ duración).
- ¿Hay columnas con valores negativos? ¿Es razonable que una duración o una cantidad de paquetes sea negativa?
- ¿Qué columnas son constantes? ¿Qué información aportan a un modelo? ¿Qué harías con ellas?

Tarea 4 · Limpieza (sección 5)

- ¿Cuántas filas se eliminaron por inf/NaN y cuántas por duplicados? ¿Qué porcentaje del archivo conservaste?
- Mira "Filas eliminadas por clase": ¿a qué clase pertenecían casi todas las filas eliminadas? ¿Cómo cambió la proporción de ataques y por qué crees que ocurrió?
- ¿Por qué es importante eliminar duplicados **antes** de separar entrenamiento y prueba? (Pista: ¿qué pasaría si una misma fila queda en ambos conjuntos?)

Tarea 5 · Comparación entre clases (sección 6)

- Observa los histogramas y las cajas. ¿Por qué se usa la escala `log10(1 + x)` y no la escala lineal?
- ¿Qué variables muestran diferencias claras entre benigno y ataque? ¿En cuáles las dos clases casi se superponen?
- Compara las medianas de `Flow Packets/s` y `Flow Bytes/s`: ¿cada flujo de DDoS es más intenso que uno benigno? Si no lo es, ¿dónde está realmente el "ataque"?
- Observa la tabla de **variedad de valores distintos**: ¿qué te dice que `Total Length of Fwd Packets` tenga pocos valores distintos en el ataque y miles en el tráfico benigno?

Tarea 6 · Correlaciones y poder separador

- ¿Cuántos pares de variables tienen correlación $|r| \geq 0{,}95$? Elige un par y explica por qué es lógico que estén tan relacionadas.
- ¿Qué hacer con variables casi idénticas? ¿Todos los modelos se ven afectados igual por la redundancia?
- Mira el AUC univariado. ¿Cuál es el valor más alto? ¿Alguna variable superó 0,95 y fue marcada como sospechosa?
- Si ninguna variable superó el umbral, ¿quiere decir que no hay atajos? Guarda tu respuesta y revísala después de la Tarea 7.

Tarea 7 · Puertos de destino y PCA

- ¿A qué puerto(s) apunta casi todo el ataque? ¿Qué servicio suele usar ese puerto? ¿Cómo se reparte el tráfico benigno?
- Si un modelo aprendiera "puerto 80 = ataque", ¿funcionaría en una red donde el tráfico web legítimo también usa el puerto 80? ¿Es un atajo del laboratorio o una característica real del ataque?
- El script prueba la regla "Destination Port == 80": ¿qué recall, precisión y exactitud obtiene? ¿Por qué el AUC de la sección 8 no mostró este atajo?
- En el gráfico de PCA, ¿cuántos grupos compactos forma el ataque? ¿Se solapa alguno con el tráfico benigno? ¿Qué implica para la dificultad del problema?

Tarea 8 · Conclusiones y decisiones para la práctica 2.3

Con lo observado, completa la tabla de decisiones de la sección 7: qué columnas eliminarás, qué harás con infinitos y duplicados, qué variables te generan dudas y por qué. Escribe además **dos limitaciones** de este dataset que afectarían la validez de un modelo entrenado con él.

7. Plantillas para registrar tus resultados y entregar

A. Datos del archivo

Dato	Tu valor
Archivo y día analizado	
Filas y columnas	
% de ataques y razón de clases	
Tipos de ataque presentes	

B. Calidad y limpieza

Concepto	Cantidad	Columnas / comentario
Valores faltantes (NaN)		
Valores infinitos (inf)		
Columnas con negativos		
Columnas constantes		
Filas eliminadas por inf/NaN		
Filas eliminadas por duplicados		
% de filas conservadas		
Filas eliminadas por clase		
% de ataques antes → después		

C. Las 5 variables con mayor poder separador

N.º	Variable	AUC	¿Sospechosa? ¿Por qué?
1			
2			
3			
4			
5			

D. Decisiones para la práctica 2.3

Tema	Tu decisión	Justificación
Columnas duplicadas		
Columnas constantes		
Infinitos y faltantes		
Duplicados		
Destination Port		
Variables con AUC alto y atajos (por ejemplo, el puerto)		
Variables muy correlacionadas		
Etiqueta: binaria o por tipo de ataque		

8. Qué debes entregar

- El informe de exploración con las respuestas de las tareas 1 a 8.
- Las plantillas A, B, C y D de la sección 7 completadas.
- Al menos **cuatro gráficos** generados por el script, cada uno con un comentario de dos o tres líneas.
- Dos limitaciones del dataset que afectarían la validez de un modelo.

Recuerda **EN TODO PRINTSCREEN DEBE APARECER TU NOMBRE Y APELLIDO**.
Uso de IA solo de apoyo, si se detecta que fue realizado con IA, la calificación va por la mitad de la nota.